大模型智能体在 GAIA 基准集的表现提升

1 GAIA Benchmark 说明

1.1 GAIA 任务难点

- **Knowledge Immediacy**：知识的及时性，要求能够有从互联网获取知识的能力
- **Online Learning**：在线学习、挫折学习、反思与及时调整
- **Long-Term Memory for PRS**：长时序记忆
- **Vision, Numbers and Counting**：视觉能力、数学能力
- **Format Checking**：格式检查

1.2 已有基线算法的表现

- **OAgent**：在 smolagents 原有流程上应用大量策略（RM 打分，Test-Time Scaling 等）
- **Alita**：基于工具元学习，从头开始源源不断制造工具并重用，此前实现了开源 SOTA（存疑）
- **WebDancer**：通过构建两种 Agentic 数据合成 pipeline 然后进行 RL 构建 ReAct 模式下的 DeepResearcher
- **Aworld**: 通过多 Agent 前向流程收集多样数据，反向过程训练提升基础能力，实现持续演化
- https://huggingface.co/spaces/gaia-benchmark/leaderboard

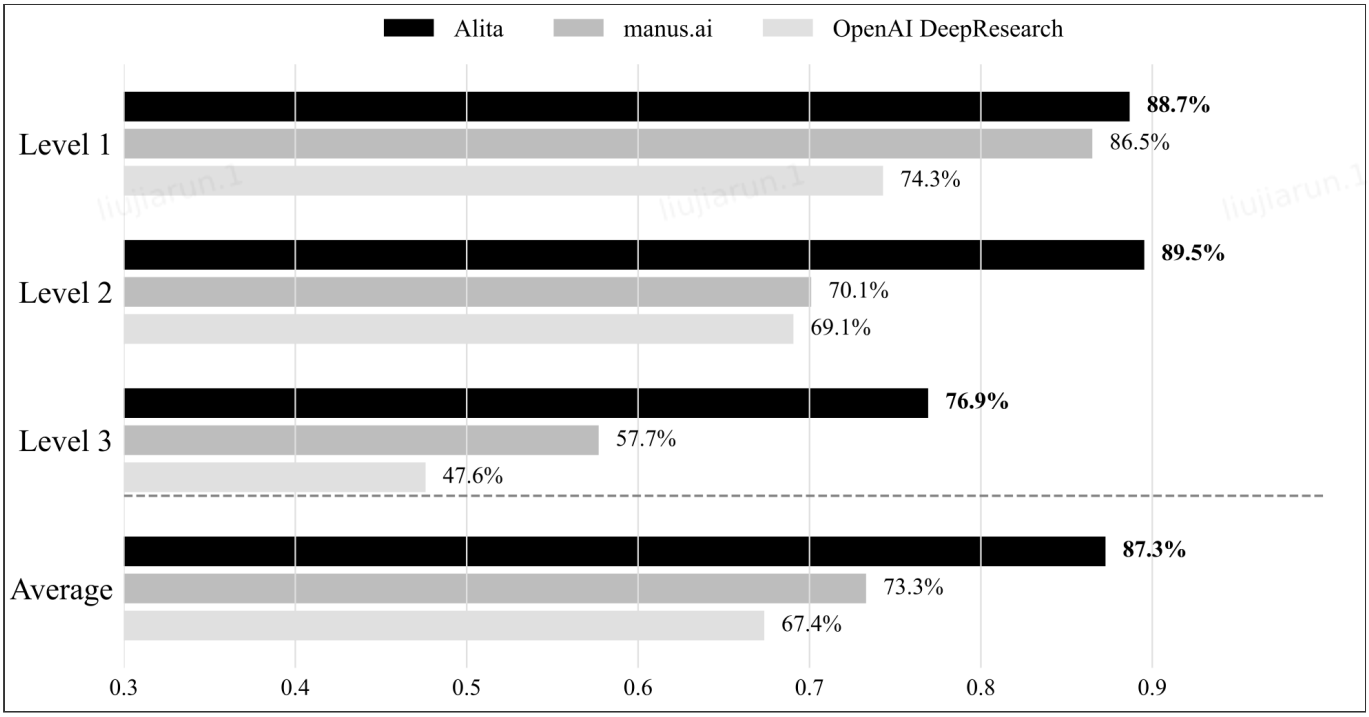

2 算法优化说明

2.1 工具设计

Python 代码解释器工具

在独立环境中运行 Python 脚本，保证工具完备性和灵活性

`PythonInterpreter`	Write and execute python code directly.

搜索工具

聚合搜索支持主流搜索引擎

`IntegratedSearchTool`	A comprehensive web search tool that can use multiple search engines (Google, Bing, DuckDuckGo,Yandex, Yahoo...).

维基百科专用搜索

`WikiSearchTool`	Searches Wikipedia for articles, with options for year filtering.

Arxiv 高级搜索

`ArxivWebSearchTool`	Performs advanced searches on ArXiv for scientific papers, with support for field-specific queries and date filtering.

Github 高级搜索

`GitHubRepoSearchTool`	Searches for GitHub repositories with advanced filtering options.
`GitHubIssueSearchTool`	Searches for issues within a specified GitHub repository.
`GitHubPullRequestSearchTool`	Searches for pull requests within a specified GitHub repository.
`GitHubReleaseSearchTool`	Lists releases for a repository or retrieves a specific release by tag.

解析工具

解析各类不同模态的中间文件，实现多模态理解

`html_parse_tool`	Parses and extracts content from local HTML files.
`image_parse_tool`	Analyzes image content using a Vision Language Model (VLM), providing descriptions or answering questions about the image.
`audio_parse_tool`	Transcribes various audio formats (WAV, MP3, M4A, FLAC) using the OpenAI Whisper model.
`doc_parse_tool`	Parses and extracts content from Microsoft Office documents (Word, Excel, PowerPoint).
`ocr_tool`	Extracts text from images using Optical Character Recognition (OCR).
`pdb_parse_tool`	Parses and analyzes Protein Data Bank (PDB) files for molecular and structural data.
`PDFParseTool`	An advanced tool for parsing PDFs, with options to use either a traditional library or a VLM for extraction.
`CrawlWebpageTool`	Accesses and extracts formatted content (Markdown or HTML) from webpages.
`CrawlerArchiveWebpageTool`	Retrieves archived versions of webpages from the Wayback Machine for a specific date.
`download_file`	Downloads files from URLs with support for various formats and saves them locally.
`WikiPageTool`	Retrieves and cleans the content of a Wikipedia page from a given URL.
`visit_ytb_page`	Parses a YouTube video page to extract structured information like title, description, and stats.
`get_ytb_screenshot`	Captures a screenshot from a YouTube video at a specified timestamp.
`get_ytb_subtitle`	Downloads subtitles for a YouTube video in a specified language.
`get_ytb_audio`	Extracts the audio track from a YouTube video and saves it as an MP3 file.
`extract_zip_file`	Extracts the contents of a ZIP archive to a specified directory.

`text_parse_tool`	A general-purpose tool for parsing various text-based files, including plain text, Markdown, and structured data formats (JSON, CSV).

2.2 多智能体中的层次化记忆

- 分不同角色，实现记忆分管
- 设计了不同 Agent Node 之间的通信协议，保证结构化的信息交换
- 基于 Mem0 改进，在历史超长情况下实现了语义层面的记忆压缩

2.3 多架构设计与融合

基于开源社区主流的 SmolAgent 架构进行改进（Plan-Execute 范式）：

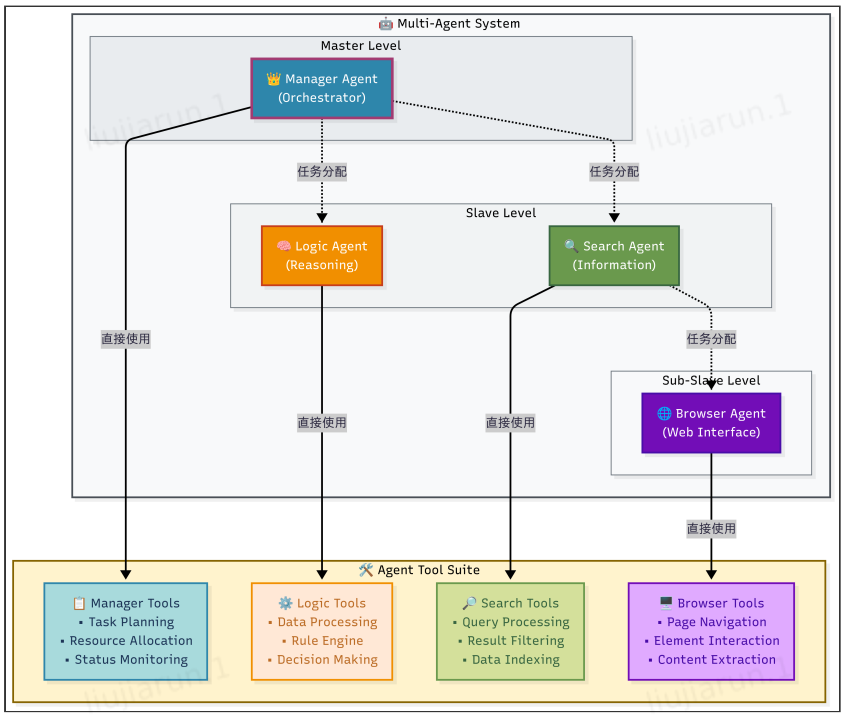

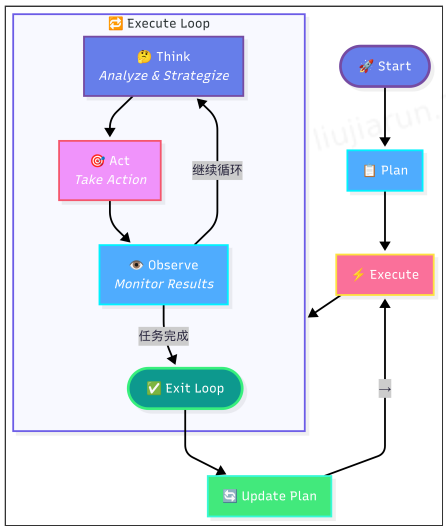

基于 ReAct 算法实现的 Agent（ReAct 范式）：

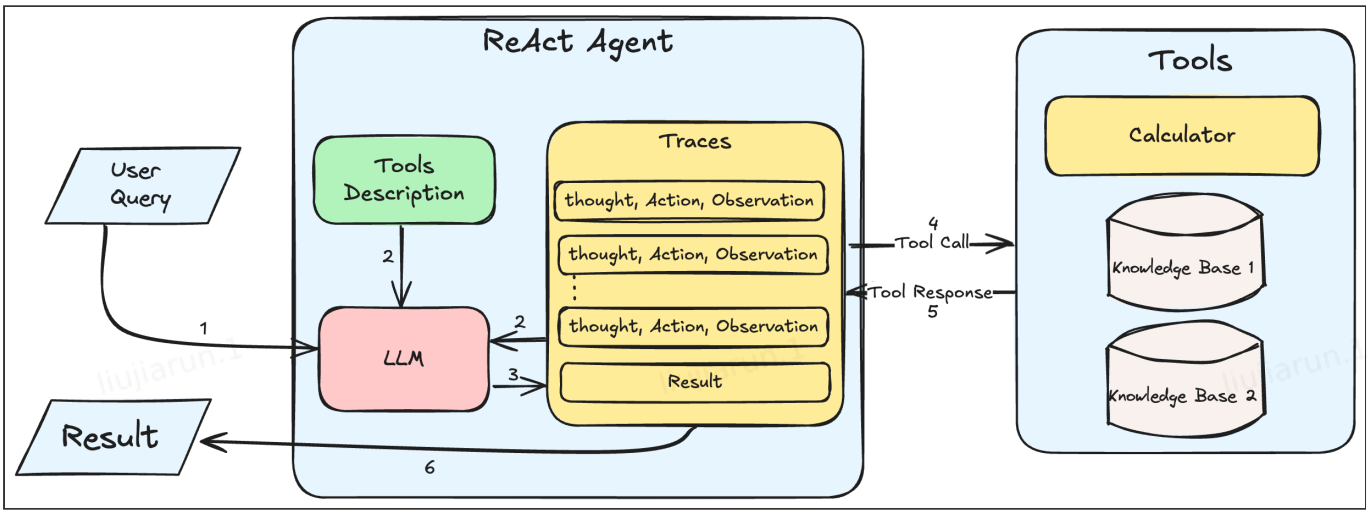

多智能体配合方案：

- ReAct Agent 设计为 **Single Agent**

- 改进版 SmolAgent 设计为 **Supervisor Agent**
- 实现了**模型融合，**基于概率方法的后验投票（三个模型），整体属于 **Hierarchical Agent**

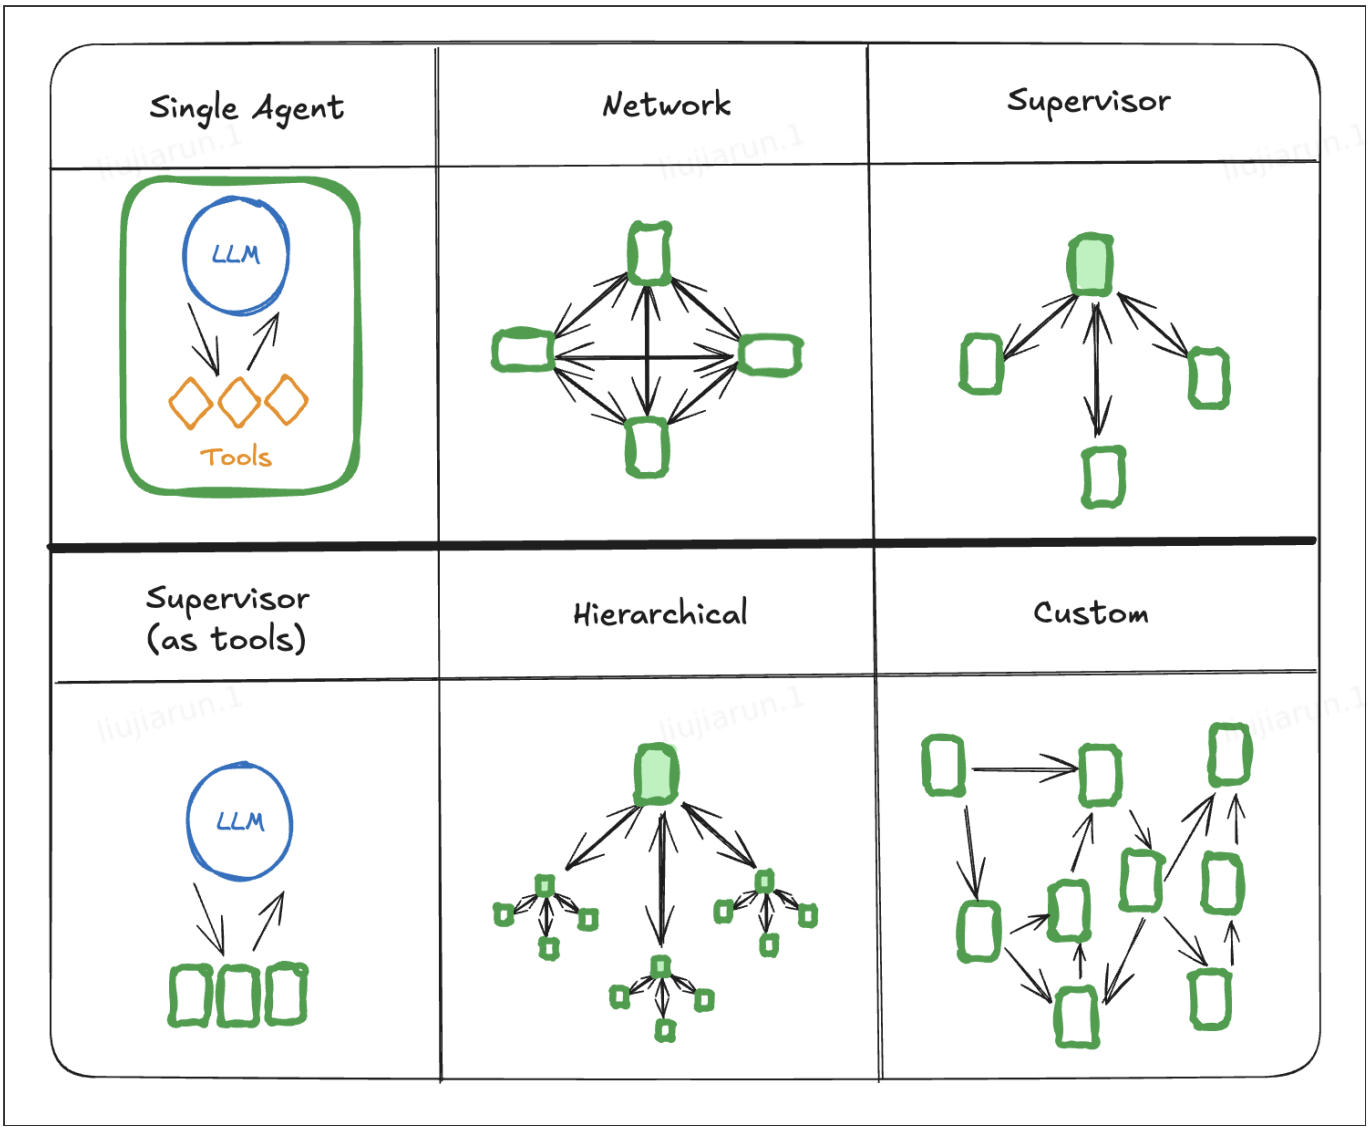

超参数调整：

- 试验不同模型基座的表现：选取了 o4-mini 和 claude-sonnet-4
- 高温度采样（大于或接近 1）在模型融合框架下可以增加多样性
- 多次提示词优化：Identity 身份，Instruction 指导，结构化输出声明，特殊情况说明等

3 分数与表现

3.1 分数和涨幅

- 相比上月从 60%，不断迭代改进，逐步提升到 71.5%

2	Whole ACC		60%	67.9%	71.5%
3	00d579ea-0889-4fd9-a7…	Claude Shannon	Oliver Selfridge	Jerome Wiesner	Oliver Selfridge
4	023e9d44-96ae-4eed-b9…	8	24.75	8	
5	0383a3ee-47a7-41a4-b4…	Rockhopper penguin	Emperor penguin	Rockhopper Penguin	
6	04a04a9b-226c-43fd-b3…	41	41	51	42
7	0512426f-4d28-49f0-be7…	100000000	100000000	100000000	100000000
8	05407167-39ec-4d3a-a2…	Format Document	Format Document	Format Document	Format Document
9	076c8171-9b3b-49b9-a4…	Finance	Finance	Finance	
10	08c0b6e9-1b43-4c2e-ae…	orange, white	orange, white	orange, white	
11	08cae58d-4084-4616-b6…	2018	2018	2004	2018
12	08f3a05f-5947-4089-a4c…	2	2	3	
13	0a3cd321-3e76-4622-91…	Brunei, China, Morocco, Si…	Brunei, China, Morocco, Singapore	Brunei, China, Morocco, Singapore	Algeria, Bahrain, Brunei, China, Ga…
14	0a65cb96-cb6e-4a6a-8a…	Holabird	Holabird	Holabird	
15	0b260a57-3f3a-4405-9f2…	0.269	insufficient data		
16	0bb3b44a-ede5-4db5-a5…	536	536	536	491
17	0bdb7c40-671d-4ad1-9c…	White; 5876	White;5876	White;5875	
18	0e9e85b8-52b9-4de4-b4…	1927	none		
19	0ff53813-3367-4f43-bcbd…	beta geometric	Beta Geometric	beta geometric	
20	114d5fd0-e2ae-4b6d-a65…	4	11	4	OUT OF STEPS
21	11af4e1a-5f45-467d-9ae…	6	6	6	
22	14569e28-c88c-43e4-8c…	backtick	backtick	backtick	
23	16d825ff-1623-4176-a5b…	6:41 PM	7:21 AM	UNKNOWN	OUT OF STEPS
24	17b5a6a3-bc87-42e8-b0…	34689	34689	34689	34689
25	1dcc160f-c187-48c2-b68…	3	3	3	3
26	1f975693-876d-457b-a6…	132, 133, 134, 197, 245	132,133,134,197,245	132, 133, 134, 197, 245	
27	20194330-9976-4043-86…	4	0	1	
28	23dd907f-1261-4488-b2…	2	2	6	2
29	27d5d136-8563-469e-92…	(¬A → B) ↔ (A ∨ ¬B)	(¬A → B) ↔ (A ∨ ¬B)	(¬A → B) ↔ (A ∨ ¬B)	
30	2a649bb1-795f-4a01-b3…	3.1.3.1; 1.11.1.7	206-353-9;500-018-3	3.1.3.1;1.11.1.7	3.1.3.1; 1.11.1.7
31	2b3ef98c-cc05-450b-a71…	To be or not to be that is th…	to be or not to be that is the question wheth…	To be or not to be that is the question …	to be or not to be that is the question

- 在 3 次模型融合后达到了 **75.15% 的分数**
  - **Plan-Execute SmolAgent** + `claude-4-sonnet`
  - **Plan-Execute SmolAgent** + `o4-mini`
  - **ReAct Single Agent** + `claude-4-sonnet`
- 如果改为 hit@3（即三次有一次命中即可），**可以达到 86% 的分数**
- 在 Benchmark 上超越大部分开源算法表现：

liujiarun.1

Validation集效果 75.15%

Agent	Score	Score_level1	Score_level2	Score_level3	机构
Alita v2.1	0.8727	0.8868	0.8953	0.7692	Princeton
Skywork	0.8242	0.9245	0.8372	0.5769	天工
AWorld	0.7758	0.8868	0.7791	0.5385	Ant Group
Langfun	0.7697	0.8679	0.7674	0.5769	DeepMind
JoyAgent-JDGenie	**0.7515**	**0.8679**	**0.7791**	**0.4230**	**JD**
OWL	0.6909	0.8491	0.6744	0.4231	CAMEL
Smolagent	0.5515	0.6792	0.5349	0.3462	Huggingface
AutoAgent	0.5515	0.7170	0.5349	0.2692	HKU
Magentic	0.4606	0.5660	0.4651	0.2308	MSR AI Frontiers
LRC-Huawei	0.406	0.5283	0.4302	0.0769	Huawei
xManus	0.4061	0.8113	0.2791	0.0000	OpenManus

实验记录与分析（日更）

3.2 错误分析

- 网页导航、browser use、网页自动化，实现网页操纵交互

2020年1月Arxiv上“高能物理-晶格”论文中有**多少 postscript 版本可用**?	`31`

- 理解低清晰度、畸变类、OCR 等图片

请以逗号分隔、无空格的形式，**按图像中出现的先后顺序**，列出所有使用“/”作为分数线的分数以及示例题的答案。	`3/4,1/4,1/2,5/35,7/21,30/5,6/8,4/60,30/90,8/18,9/72,64/46,206/340,3/4,1/15,1/3,4/9,1/8,32/23,103/170`

- 低频、过时、深藏的网页信息获取

在2022年最新的乐高的英文维基百科中**有多少张图片**?	`12`

- 地图类工具的感知与理解

找出坐标 -48.8583701, -177.7077074 的对跖点坐标。然后**在谷歌地图街景中前往该位置**，并朝向可见的最高建筑物，此时面对哪个方向?	`east`

- 长文本、大 PDF 的知识定位与处理

在美国国立卫生研究院（NIH）翻译的 1913 年**原始 Michaelis-Menten 论文**中，基于 Excel 文件中反应 7（Reaction 7）的信息，使用论文中的最终公式，反应速率精确到**小数点后四位**是多少？	`0.0424`

- 复杂数学推理、逻辑推理等

当 0.312 千克的氟利昂-12 **制冷剂被放置在马里亚纳海沟底部，并在海沟的最高温度下稳定下来时，该系统的体积是多少毫升**？请将你的答案四舍五入到最接近的毫升，并只提供一个整数作为答案。	`55`

4 后续工作

4.1 算法劣势分析

- **工具学习**
  - 工具内部迭代优化受限，大模型无法直接访问
  - 工具集合构成的工具空间基仍然不完备
  - 无法针对新任务产生新工具，工具在 Validation 上过拟合
- **记忆利用与探索**
  - 无法利用错误反馈
  - 对跨任务记忆没有充分利用
  - 当前 GAIA 的聚类分析（任务描述与步骤的权衡分数），证实了大量任务的相似性

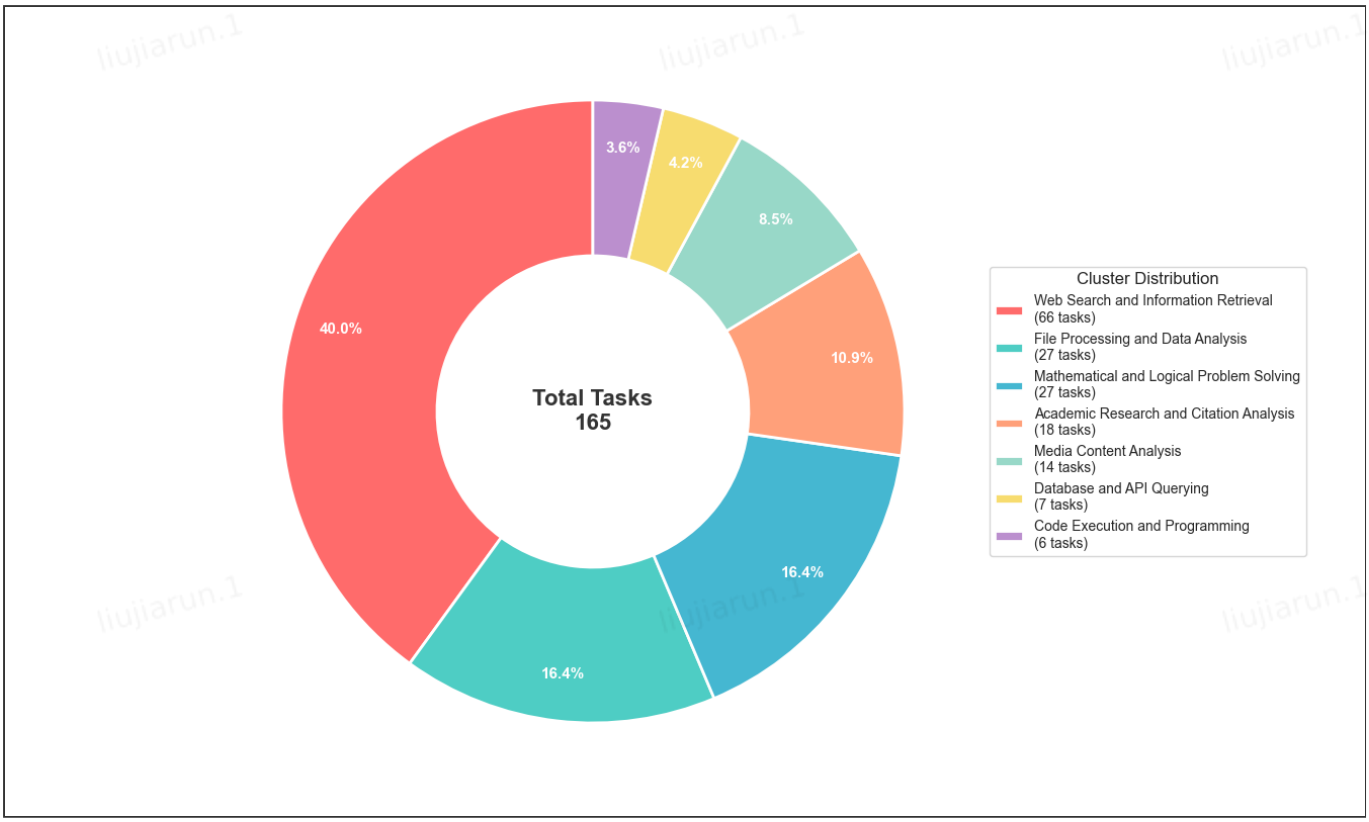

- **代码生成**

- 遇到错误 debug 效果差
- 只会写简单代码，高级编程能力差
- 无法使用广大的开源第三方库

4.2 创新点说明

- **Agent 自己造工具**，检索先验知识（已有 tools 的代码）实现精准的推理增强
- **Agent 从自己的成功任务中学习经验**，实现跨任务学习（超长期记忆）
- **专门的子 Agent 负责 debug 代码错误、分析与反馈**，更细粒度的分层学习
- **模型差异与多样性采样，单独的 critic 语义投票模块**

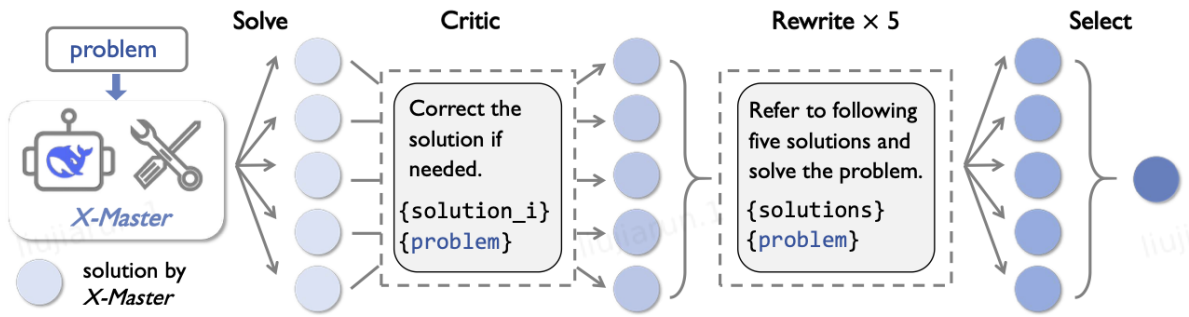

Figure 3: Overview of our *X-Masters*, a scattered-and-stacked agentic workflow. The workflow leverages *X-Master* as different roles to enhance solution quality at inference. It includes (1) Solvers generating five initial solutions, (2) Critics refining the initial solution, (3) Rewriters synthesizing all five solutions to generate new five, and (4) Selector choosing the best solution.

- **知识增强的工具元学习**
  - **通过不断写代码解决计划**，通过不断解决一系列计划解决任务本体
  - 基于原本的工具函数构建小样本提示，任务相似度匹配 RAG
  - 成功任务生成的新工具代码，入库 RAG，形成跨任务复用迭代
- **跨任务经验学习**
  - 每次任务成功，将计划和代码的记忆入库 RAG
  - 下次见到类似的任务，将过去的记忆作为小样本示例返回
- **基于团队任务分配的多智能体协同**
  - 产品经理、开发、测试与投票四人协同
  - 更细粒度的层次化记忆，保证更好地上下文维护
- **基于基模的多路径采样**
  - OpenAI、Claude、Gemini 基模一致性约束
  - Critic 裁判智能体基于推理实现投票

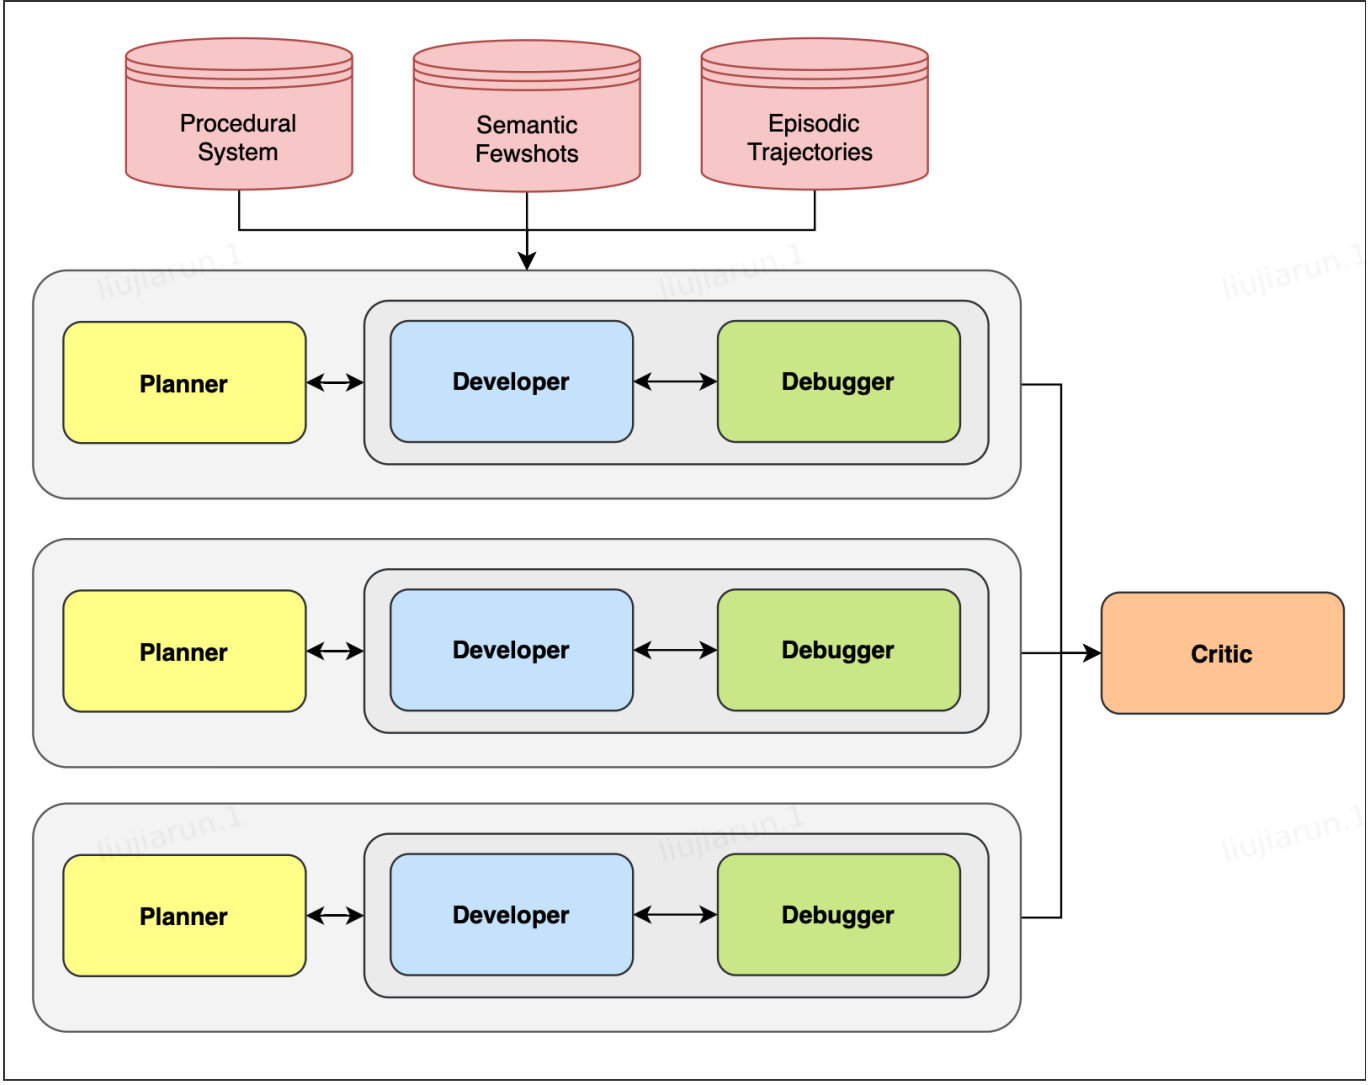

4.3 算法性能与表现

- **目前在 GAIA 共 93 个 task 上运行实验（共 160 个），达到了 84.94% 的准确率**
- 在 baseline 算法成功的案例上保持稳定性，同时在一些不稳定任务上收敛
- 跨任务记忆支持后续任务的一致性
- 有望提高整体分数

4.4 案例分析

如下是一个很典型的中等难题，此前的一些 Agent 都没有做对该题（即 Plan-Execute 和 ReAct Agent）。

> ☞ e29834fd-413a-455c-a33e-c3915b07401c
>
> I'd like to learn more about some popular reality television competition shows. As of the end of the 44th season of the American version of Survivor, how many more unique winners have there been compared to the number of winners of American Idol?

首先是 Planner 的 Episodic Memory 从这条实验记录过去的成功轨迹召回的记忆。这些过去的 task 都是成功的、与当前新任务在意图层面上语义相关的。

▸ Planner Memory

之后是 Developer 的 Episodic Memory。

Developer Memory

可以看到，不同角色的子智能体都回忆起了之前执行的意图层相关任务，这些任务（1）一方面可以作为 shortcut 允许智能体快速接入任务分解和代码生成（2）一方面增加模型输出一致性。

如下是 critic 子智能体在最后步骤时，进行一致性检查的投票决策；可以看到，尽管两个模型回答错误、一个模型回答正确，critic 仍旧能根据正确模型的交互链路判断其为对。这是以往算法的后验投票无法做到的。

Critic

```
(1) Task decomposition: Determine number of unique Survivor winners through Season 44 and number of American Idol winners as of the comparable timeframe, then compute the difference. Success criteria: accurate counts and correct subtraction. (2) Member evaluation: Member 1 scraped 23 “Season” entries for American Idol but erroneously assumed 23 seasons; logic coherent but factually incorrect. Member 2 correctly identified 42 unique Survivor winners (44 wins minus two repeat champions) and 21 American Idol winners (Seasons 1-21), then computed 42-21=21; methodology and data accuracy solid. Member 3 mirrored Member 1’s incorrect American Idol count of 23, leading to a flawed difference. (3) Cross-analysis: Agreement on 42 unique Survivor winners; divergence on American Idol seasons (23 vs 21). Verification against known broadcast history confirms 21 seasons completed by end 2023. (4) Synthesis: Adopt Member 2’s validated counts and subtraction. (5) Validation: Independent check of Survivor repeat winners (Sandra Diaz-Twine, Tony Vlachos) and American Idol season tally confirms result. (6) Confidence: high - final answer meets all task requirements and factual benchmarks.
```

如下则是智能体在任务成功后，自我学习过程中产生的新记忆，即新的工具元函数、新的意图分解链路。

如下是其中一新的工具函数样例。

Meta-tool

如下是新算法自己安装的 python package，由此说明工具元学习放宽了 Coding Agent 的动作空间，为智能体提供了更广阔的开源工具平台，甚至包括 mcp 工具。

```
pdfplumber
serpapi
scholarly
mwparserfromhell
requests_html
whisper
openai_whisper
faster_whisper
yfinance
cloudscraper
lyricsgenius
googletrans
fastmcp
```

```
Plan generated: Access the poem 'Father Son and Holy Ghost' by Audre
 Lorde through the MCP server's file system capabilities or any avail
able local resources. Check if there are any poetry databases, text f
iles, or l...
```

4.5 技巧（tricks）

- **课程学习的难度重估计：**在优化算法前，我们基于主流开源 Agent 算法进行批量实验，根据模型的实际执行难度（平均成功率）重新标记任务的 task level，得到模型一致的数据难度分布阶梯；有利于课程学习，即 Agent 先完成简单任务并积累对应的代码片段记忆（semantic memory），逐步形成滚雪球效应；

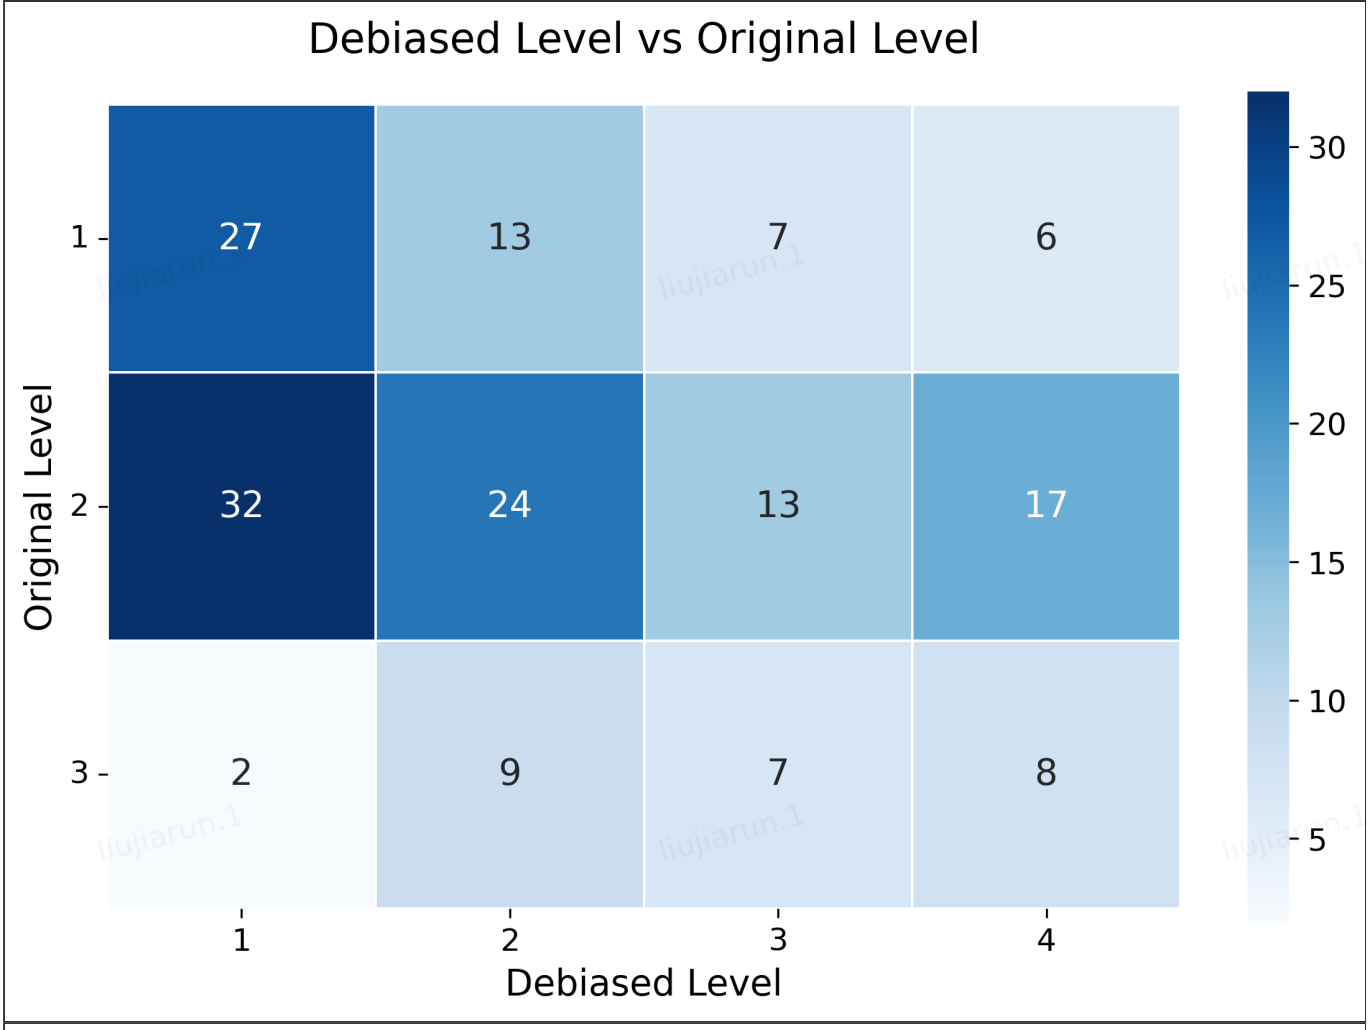

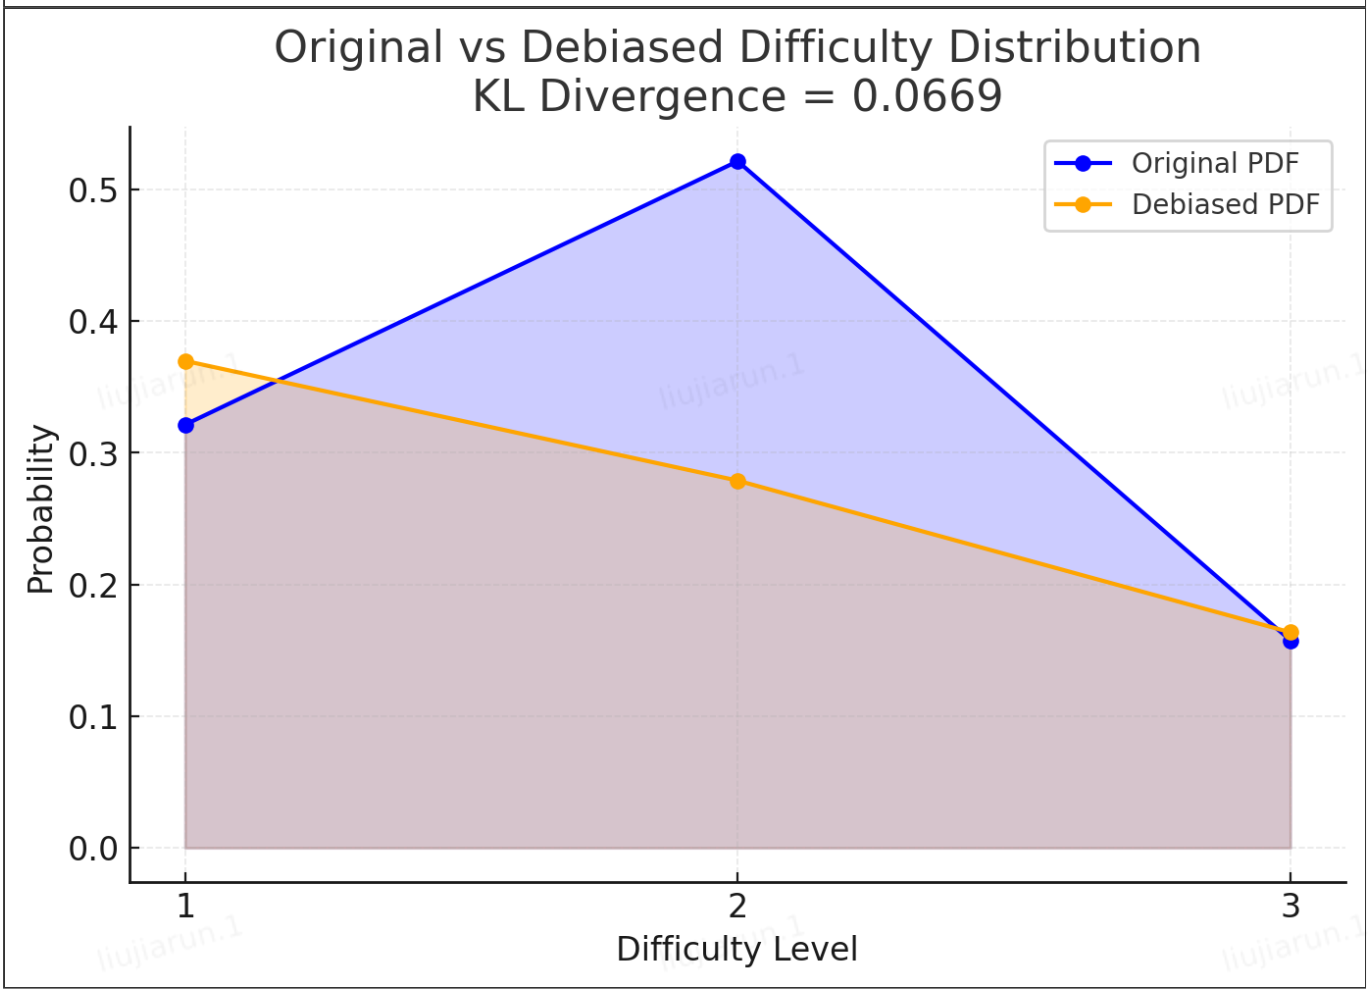

- **任务退避：** （1）任务的执行顺序已经由**重估计后的难度**进行重排（2）当某个任务失败后，将其退后 `k=10` 个直到不能再退后，以保证智能体可以在学习与进化后重新挑战；

- **多模型多采样广泛实验：**（1）先针对每个 task 样本超参数进行 grid search（例如某个任务在 `claude-4-sonnet` 结合高温 `0.8` 时可以正确回答），即单链路实验（2）在多链路采样上，尽可能保证同模型或同温度（3）完成一批任务后，如 `batch = 25`，根据 task intent 聚类分布与超参数分布的**联合分布**，对后续任务的模型超参数进行优化，即从该联合分布进行采样；

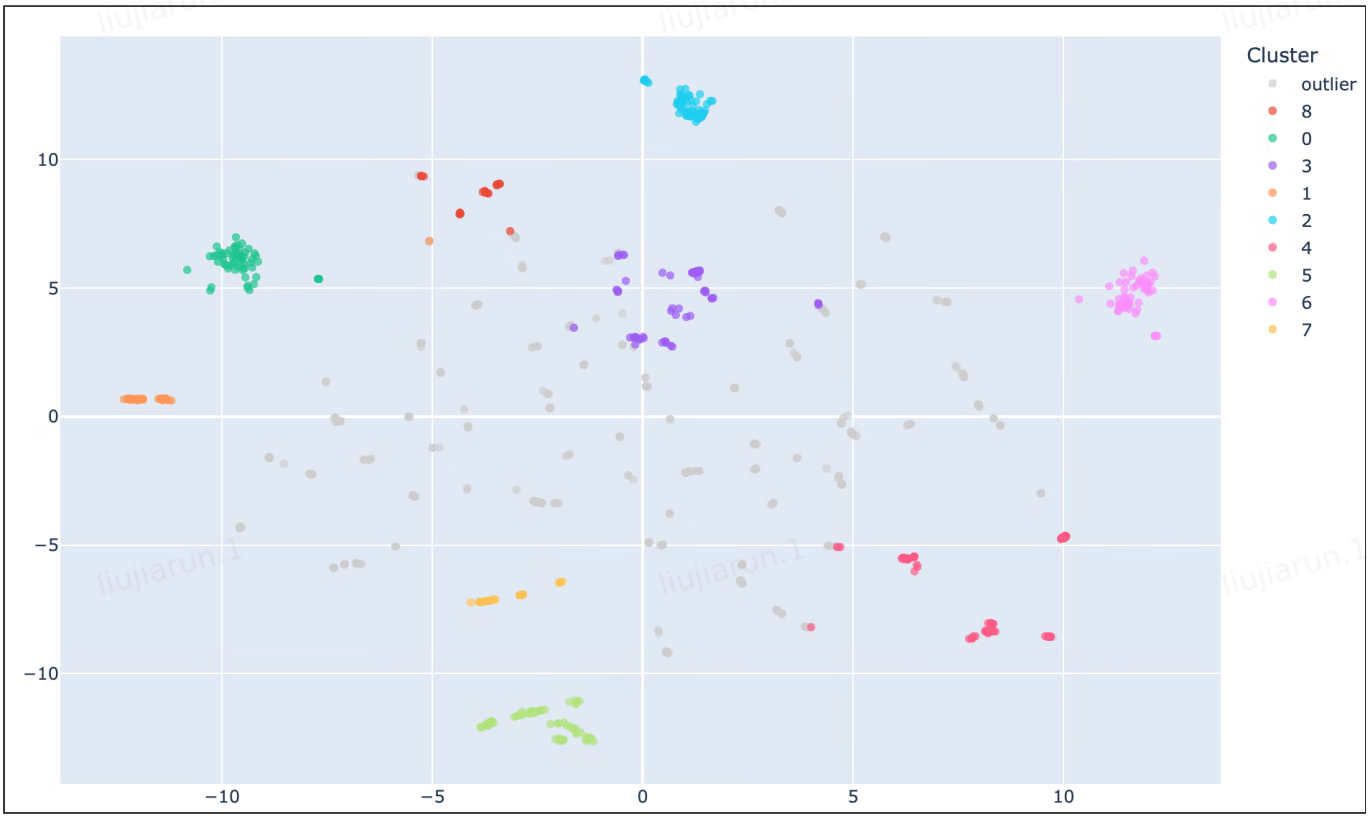

- **工具一致性控制：**随着实验的推移，不断降低原 semantic memory 检索占比，同时适当增大（或不改变）新生成（成功经验学习）的 episodic memory 的占比，从而推动 developer 智能体代码生成分布的演进；
- **人在环路指导（后期）：**随着任务难度达到 level 3 以上，模型会经常受挫，此时，对任意的子智能体，靠近初始时刻的**决策重要性**往往大于后续决策（好的开始是成功的一半）；因此，可以必要地在任务执行前提供一些指导（请注意，这些**指导不属于作弊**）；具体而言，我们明确规定指导暂时只有一种，即提供一指向外部第三方代码库或知识文档的 URL 以及说明 `(URL, description)`，以更好地、更准确地导航智能体的工具知识获取与利用；