目录

通用 Agent 训练数据收集

正文 1503 字（2 页） | 浏览 130 次（13 人） 全部 >

AI 速览 点击生成简要速览，支持更多 风格切换 助你高效阅读

通用 Tool-Use 训练数据

1. 基本简单工具（如计算器，日历，记事本，指南针，天气，电话本，邮件等，刷 BFCL、Tau-Bench）；
2. 浏览器类（刷 BrowserComp）；
3. 代码工具 (如 python 解释器，C++ 编译链，java 环境，bash 脚本，刷 SWE-bench、Polyglot)；
4. 存储地址见 /mnt/dolphinfs/hdd_pool/docker/user/hadoop-mtsearch-assistant/ai-search/data/general_agentic_training。

	名称	引用	链接	样本数
简单工具	ToolBench	Qin et al. (2024)	https://drive.google.com/file/d/16nMO_blRS9ZIC3xs4FqjJ_Wwk0jwC4ph/view	126486
	ToolACE	Microsoft (2024)	https://huggingface.co/datasets/Team-ACE/ToolACE	180K
	xLAM	Salesforce (2024)	https://huggingface.co/datasets/Salesforce/xlam-function-calling-60k	60K
	ToolAlpaca	https://arxiv.org/abs/2306.05301	https://github.com/tangqiaoyu/ToolAlpaca	3900

	ReTool	https://retool-rl.github.io	https://huggingface.co/datasets/JoeYing/ReTool-SFT	4000
通用大全	AgentInstruct	https://arxiv.org/pdf/2407.03502	https://huggingface.co/datasets/microsoft/orca-agentinstruct-1M-v1	25M
在线检索	WebWalkerQA	https://arxiv.org/pdf/2501.07572	https://huggingface.co/datasets/callanwu/WebWalkerQA	14259
	WebExplorer-QA	https://arxiv.org/abs/2509.06501	https://huggingface.co/datasets/hkust-nlp/WebExplorer-QA	100
	WebShaper	https://arxiv.org/abs/2507.15061	https://huggingface.co/datasets/Alibaba-NLP/WebShaper	500
	AgentTrek	https://arxiv.org/pdf/2412.09605	https://huggingface.co/datasets/xlangai/AgentTrek	52594
代码工具	Magicoder	Wei et al. (2023)	https://huggingface.co/datasets/ise-uiuc/Magicoder-OSS-Instruct-75K	75K
	InterCode	Yang et al. (2023)	https://github.com/princeton-nlp/intercode/tree/master/data	1351
	KodCode	https://arxiv.org/abs/2503.02951	https://huggingface.co/datasets/KodCode/KodCode-V1	447K

通用问答类数据

面向通用搜索引擎，DeepResearch，外置知识库等，刷 GAIA。

	名称	引用	链接	样本数
在线检索	WebWalkerQA	https://arxiv.org/pdf/2501.07572	https://huggingface.co/datasets/callanwu/WebWalkerQA	14259
	WebExplorer-QA（可用但要合成数据）	https://arxiv.org/abs/2509.06501	https://huggingface.co/datasets/hkust-nlp/WebExplorer-QA	100
	WebShaper（query 太长，偏研究）	https://arxiv.org/abs/2507.15061	https://huggingface.co/datasets/Alibaba-NLP/WebShaper	500
	AgentTrek（偏差大）	https://arxiv.org/pdf/2412.09605	https://huggingface.co/datasets/xlangai/AgentTrek	52594
	DeepResearch-SFT（query 太长，偏研究）		https://huggingface.co/datasets/FractalAIResearch/DeepResearch-SFT	2460
	dr-tulu-sft-data		https://huggingface.co/datasets/rl-research/dr-tulu-sft-data	13100
	dr-tulu-rl-data		https://huggingface.	4880

			co/datasets/rl-research/dr-tulu-rl-data	
	MiroVerse-v0.1		https://huggingface.co/datasets/miromind-ai/MiroVerse-v0.1	67200
	DuetQA-Verified		https://huggingface.co/datasets/FractalAIResearch/DuetQA-Verified	4890

目前比较直接可用数据，已用绿色标识。大概在 **13100 + 67200 = 80300，大约八万条 SFT 数据，**这些数据包含（1）基于推理思维链的过程（2）至少一个检索工具调用（3）大部分为多轮，也有单轮（4）符合现代 OpenAISchema，不符合也可以转换（5）MiroVerse 包含了科学性问题，如 MiroVerse-MegaScience（10.6K），如果去除大概还剩 80300 - 10600 = 69700，约七万条数据。

通用攻略类（小红书 like）

VitaBench Longcat 提出的，配送、店内消费和在线旅行服务等日常应用场景。

仅供内部使用，未经授权，切勿外传