		总体
	其他	其他

SafetyBench 的核心思路是把流程拆成三段，便于替换模型与评测器：

1. `generate` （rollout）：被测模型基于真实 `system/user/tool` prompt 生成回答。
2. `judge` ：使用独立 judge 模型（推荐 Gemini）判定 `is_reject` 。
3. `result` ：聚合结果，输出 `reject_precision / reject_recall / reject_f1` 。

2. 数据内容

主数据字段包括：

- `id`
- `query`
- `type_1 / type_2 / type_3`
- `should_reject`
- `location / lat / lng` （含 fake geo）

本仓库当前使用的 benchmark 文件：

- `./benchmark_480_eval_with_fake_geo.jsonl`

3. 运行环境

代码块 Shell

```shell
bash setup_local_h20_vllm_env.sh
```

4. 如何注册一个新模型

统一在 `config/model_pool.json` 的 `profiles` 下注册。

每个 profile 必填：

- `deploy` ：
  - `model_path`
  - `host`
  - `port`
  - `tp_size`
  - `gpu_memory_utilization`

  - `max_model_len`
  - `dtype`
- `served_model_name`
- `eval`：
  - `provider`（固定 `openai_compatible`）
  - `base_url`
  - `model_name`
  - `model_display_name`

示例：

代码块 JSON

```
{
  "profiles": {
    "my_model": {
      "served_model_name": "hf32b-local",
      "deploy": {
        "model_path": "/path/to/your/model",
        "host": "0.0.0.0",
        "port": 8000,
        "tp_size": 1,
        "gpu_memory_utilization": 0.92,
        "max_model_len": 40000,
        "dtype": "bfloat16"
      },
      "eval": {
        "provider": "openai_compatible",
        "base_url": "http://127.0.0.1:8000/v1",
        "model_name": "hf32b-local",
        "model_display_name": "HF-32B-MyModel"
      }
    }
  }
}
```

5. 命令

5.1 启动本地被测模型（示例：truncated）

代码块 Shell

```shell
bash deploy_hf32b_h20.sh --profile truncated

```

5.2 一条龙评测（generate + judge + result）

代码块 Shell

```shell
cd /mnt/dolphinfs/hdd_pool/docker/user/hadoop-mtsearch-assistant/ai-search/zhangkaizhou/safety_benchmark

export PROJECT=qwen32b_truncated
export INPUT=benchmark_480_eval_with_fake_geo.jsonl
export MODELS_KEYS=truncated
export MODEL_POOL_FILE=config/model_pool.json

# rollout 工具调用鉴权
export TOOL_HTTP_TOKEN="<your_tool_http_token>"

# judge 模型鉴权（Gemini）
export APP_IDS="<your_gemini_appids_comma_separated>"

STEPS=generate,judge,result \
bash run_pipeline.sh eval \
  --judge-mode is_reject \
  --align-mode order \
  --model gemini-3-flash-preview

```

6. 输出位置

运行完成后默认输出：

- `eval/result/${PROJECT}/outputs/<model_key>_answers.jsonl`
- `eval/result/${PROJECT}/outputs/judged_<model_key>.jsonl`
- `eval/result/${PROJECT}/result/result_<model_key>.json`

例如（`PROJECT=qwen32b_truncated`）：

- `eval/result/qwen32b_truncated/outputs/truncated_answers.jsonl`
- `eval/result/qwen32b_truncated/outputs/judged_truncated.jsonl`
- `eval/result/qwen32b_truncated/result/result_truncated.json`

7.Evaluation Result

	precision	recall	F1
qwen32B	**0.7208**	0.5917	0.6499
reasoning	0.5397	**0.9625**	**0.6919**
truncated	0.5343	0.9417	0.6817

Agent-SafetyBench

SOP

Agent-SafetyBench 支持两种生成方式：vllm 加载本地模型和使用 API。

vllm 示例：

代码块 Shell

API 示例：

代码块 Shell

在 `open-benchmarks/Agent-SafetyBench/evaluation/eval_vllm.py` 或 `open-benchmarks/Agent-SafetyBench/evaluation/eval.py` 中的 `outdir` 可以指定输出路径。示例：

```
outdir = f"./evaluation_results/tot-{model_name}-truncated"
```

生成完成后通过 `open-benchmarks/Agent-SafetyBench/score/eval_with_shield.sh` 脚本进行评测：

代码块 Shell

注意指定文件的路径（和前面生成的保持一致）：

代码块 Shell

Evaluation Results

Model	Total	Leak	Property	Spread	P
qwen3-32b	41.57	40.80	42.40	22.09	4

reasoning	55.25	58.40	51.20	36.00	4
truncated	53.88	56.80	50.00	**38.00**	4
Claude-3-Opus	**59.8**	**60.4**	**60.4**	35.6	**6**
GPT-4o	44.2	44.4	48.4	12.4	5

Wildjailbreak

SOP

wildjailbreak 通过 `run.sh` 封装了生成和评测两部分，可以一键运行。（评测默认使用 gemini-3-flash 作为 judger）

代码块 Shell

在里面可以指定结果保存路径，使用的模型等：

代码块 Shell

Evaluation Results

Model	Safe rate
qwen3-32b	35.95
reasoning	83.57
truncated	**85.25**
tulu-2-7b	35.6
mistral-7b	25.4

仅供内部使用，未经授权，切勿外传

刘嘉润439411966
C-3